

微积分

微积分

- ◆ 导数、微分、积分
- ◆ 链式求导法则
- ◆ 反向传播算法

导数

◆ 导数的概念

导数是数学中的一个基本概念，主要用于研究函数随变量变化的快慢，即变化率。给出一个函数 $f(x)$ ，如果我们想要计算在某一点 $x = a$ 处的导数，我们会考虑函数在 x 接近 a 时的变化情况。

更正式地说，函数 $f(x)$ 在点 $x = a$ 处的导数定义为：

$$f'(a) = \lim_{h \rightarrow 0} \frac{f(a+h) - f(a)}{h}$$

如果这个极限存在，我们就说函数在点 a 是可导的

导数


◆ 常见导数

初等函数	导数
x^n	$n \cdot x^{n-1}$
e^x	e^x
a^x	$a^x \ln(a)$
$\ln(x)$	$\frac{1}{x}$
$\log_a(x)$	$\frac{1}{x \ln(a)}$
$\sin(x)$	$\cos(x)$


$\cos(x)$	$-\sin(x)$
$\tan(x)$	$\sec^2(x)$
$\arcsin(x)$	$\frac{1}{\sqrt{1-x^2}}$
$\arccos(x)$	$-\frac{1}{\sqrt{1-x^2}}$
$\arctan(x)$	$\frac{1}{1+x^2}$

激活函数求导

◆ 常见激活函数




$$\sigma(x) = \frac{1}{1+e^{-x}}$$



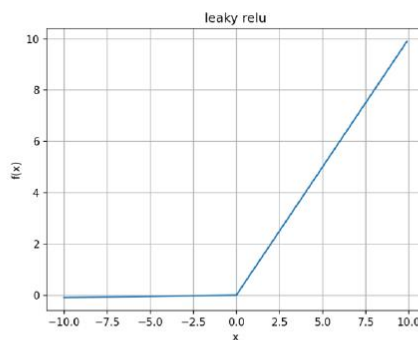
$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$

激活函数求导

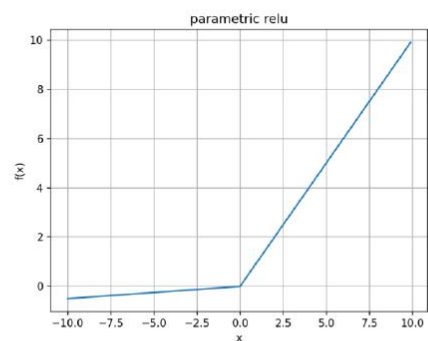
◆ 常见激活函数



$$\text{ReLU}(x) = \max(0, x)$$




$$\text{LeakyReLU}(x) = \max(0.01x, x)$$



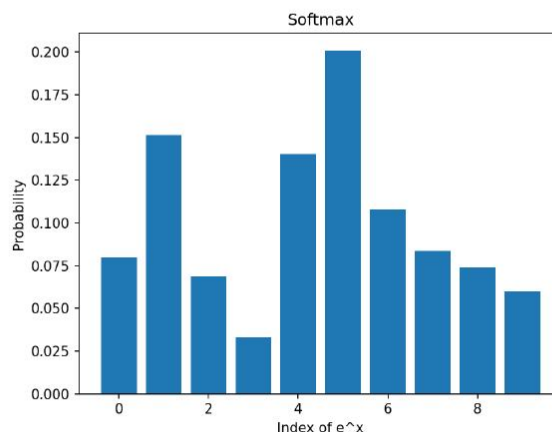
$$\text{PReLU}(x) = \max(\alpha x, x)$$

激活函数求导

◆ 常见激活函数



$$\text{ELU}(x) = \begin{cases} x, & \text{if } x > 0 \\ \alpha(e^x - 1), & \text{if } x \leq 0 \end{cases}$$



$$\text{Softmax}(x_i) = \frac{e^{x_i}}{\sum_j e^{x_j}}$$

激活函数求导

◆ 常见激活函数的导数

激活函数	表达式	导数	特点
Sigmoid	$\sigma(x) = \frac{1}{1+e^{-x}}$	$\sigma'(x) = \sigma(x)(1 - \sigma(x))$	将输入压缩到(0,1)区间, 用于二分类问题, 在深层网络中容易产生梯度消失
Tanh	$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$	$\tanh'(x) = 1 - \tanh^2(x)$	将输入压缩到(-1,1)区间, 比sigmoid有更大的输出范围, 也可能导致梯度消失
ReLU	$\text{ReLU}(x) = \max(0, x)$	$\text{ReLU}'(x) = \begin{cases} 1, & \text{if } x > 0 \\ 0, & \text{if } x \leq 0 \end{cases}$	在正区间内保持梯度不变, 解决了梯度消失问题, 但在负区间梯度为0
Leaky ReLU	$\text{LeakyReLU}(x) = \max(0.01x, x)$	$\text{LeakyReLU}'(x) = \begin{cases} 1, & \text{if } x > 0 \\ 0.01, & \text{if } x \leq 0 \end{cases}$	解决了ReLU在负区间梯度为0的问题, 允许小梯度存在
Parametric ReLU	$\text{PReLU}(x) = \max(\alpha x, x)$	$\text{PReLU}'(x) = \begin{cases} 1, & \text{if } x > 0 \\ \alpha, & \text{if } x \leq 0 \end{cases}$	ReLU的泛化形式, 其中 α 是一个可学习的参数
ELU	$\text{ELU}(x) = \begin{cases} x, & \text{if } x > 0 \\ \alpha(e^x - 1), & \text{if } x \leq 0 \end{cases}$	$\text{ELU}'(x) = \begin{cases} 1, & \text{if } x > 0 \\ \text{ELU}(x) + \alpha, & \text{if } x \leq 0 \end{cases}$	试图结合sigmoid和ReLU的优点, 输出对负值有小幅度的响应

案例实践

- ◆ 使用Python绘制出上述激活函数

微分

- ◆ 微分的概念

函数 $f(x)$ 在点 x 的微分，通常表示为 df 或 $df(x)$ ，在几何上对应于函数图像在 x 点的切线上， x 的一个小变化 dx 所引起的函数值 $f(x)$ 的变化。这个变化称为函数 f 的微分，数学上可以写作

$$df(x) = f'(x)dx,$$

其中 $f'(x)$ 是函数 f 在 x 处的导数。

微分

◆ 加法法则

如果有两个函数 $u(x)$ 和 $v(x)$ ，它们的和为 $f(x) = u(x) + v(x)$ ，那么 $f(x)$ 的导数是这两个函数导数的和：

$$\frac{d}{dx}[u(x) + v(x)] = \frac{d}{dx}u(x) + \frac{d}{dx}v(x)$$

微分

◆ 乘法法则

如果有两个函数 $u(x)$ 和 $v(x)$ ，它们的乘积为 $f(x) = u(x) \cdot v(x)$ ，那么 $f(x)$ 的导数是：

$$\frac{d}{dx}[u(x) \cdot v(x)] = u(x) \frac{d}{dx}v(x) + v(x) \frac{d}{dx}u(x)$$

微分


◆ 除法法则

如果有两个函数 $u(x)$ 和 $v(x)$ ，它们的商为 $f(x) = \frac{u(x)}{v(x)}$ ，那么 $f(x)$ 的导数是：

$$\frac{d}{dx} \left[\frac{u(x)}{v(x)} \right] = \frac{v(x) \frac{d}{dx} u(x) - u(x) \frac{d}{dx} v(x)}{[v(x)]^2}$$

积分

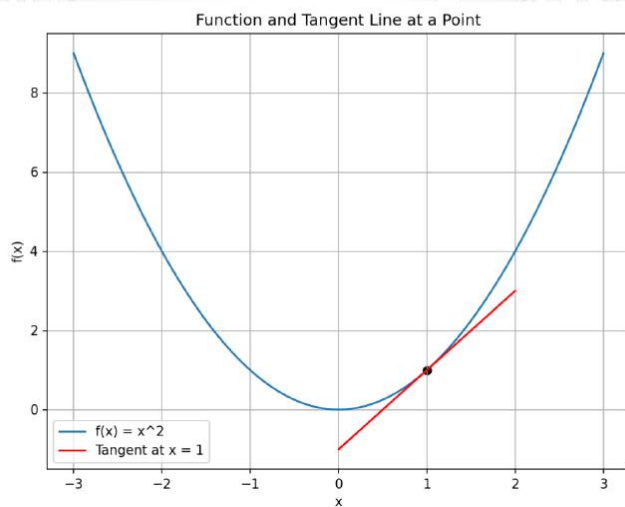
◆ 积分示意图



$$\int_a^b f(x) dx$$

案例展示


◆ 展示二维图像切线



案例展示

◆ 展示三维函数切面

3D Surface Plot with Tangent Plane



链式求导法则

◆ 链式求导法则

设有两个函数 $y = f(u)$ 和 $u = g(x)$ ，它们都在相应的点可导。如果我们定义一个复合函数 $y = f(g(x))$ ，那么复合函数 y 关于 x 的导数是：

$$\frac{dy}{dx} = \frac{dy}{du} \cdot \frac{du}{dx}$$

这里， $\frac{dy}{du}$ 是外函数 $f(u)$ 关于其变量 u 的导数，而 $\frac{du}{dx}$ 是内函数 $g(x)$ 关于 x 的导数。

链式求导法则

◆ 链式求导法则


假设有复合函数 $h(x) = (3x + 2)^2$ ，对他进行求导

令 $f(u) = u^2$ ， $g(x) = 3x + 2$

1. 首先求 $g(x)$ 的导数： $g'(x) = 3$ 。
2. 然后求 $f(u)$ 对 u 的导数： $f'(u) = 2u$ 。
3. 将 $g(x)$ 代入 $f'(u)$ 得到 $f'(g(x)) = 2(3x + 2)$ 。
4. 最后，将 $f'(g(x))$ 和 $g'(x)$ 相乘得到 $h'(x)$ ： $h'(x) = 2(3x + 2) \cdot 3$ 。

反向传播算法

◆ 求反向传播



假设:

第一层参数全部初始化为0.5


第二层参数全部初始化为1

输入 $x_1=40, x_2=80$, 目标输出 $y=60$

学习率为 $1e-5$

反向传播算法

◆ 前向传播



第一层参数全部初始化为0.5
第二层参数全部初始化为1
输入 $x_1=40, x_2=80$, 目标 $y=60$
学习率为 $1e-5$

$$\begin{aligned} z_1 &= w_{11}^1 x_1 + w_{21}^1 x_2 \\ &= 0.5 \times 40 + 0.5 \times 80 \\ &= 60 \end{aligned}$$


$$\begin{aligned} z_2 &= w_{12}^1 x_1 + w_{22}^1 x_2 \\ &= 0.5 \times 40 + 0.5 \times 80 \\ &= 60 \end{aligned}$$

$$\begin{aligned} z_3 &= w_{13}^1 x_1 + w_{23}^1 x_2 \\ &= 0.5 \times 40 + 0.5 \times 80 \\ &= 60 \end{aligned}$$

$$\begin{aligned} y' &= w_{11}^2 z_1 + w_{21}^2 z_2 + w_{31}^2 z_3 \\ &= 1 \times 60 + 1 \times 60 + 1 \times 60 \\ &= 180 \end{aligned}$$

反向传播算法

◆ 计算误差




$$\begin{aligned}y' &= w_{11}^2 z_1 + w_{21}^2 z_2 + w_{31}^2 z_3 \\&= 1 \times 60 + 1 \times 60 + 1 \times 60 \\&= 180\end{aligned}$$

$$\begin{aligned}Loss &= \frac{1}{2} (y - y')^2 \\&= \frac{1}{2} (60 - 180)^2 \\&= 7200\end{aligned}$$

第一层参数全部初始化为0.5
第二层参数全部初始化为1
输入 $x_1=40, x_2=80$, 目标 $y=60$
学习率为 $1e-5$

反向传播算法

◆ 反向传播：计算损失函数的梯度




$$\begin{aligned}\frac{\partial L}{\partial y'} &= \frac{1}{2} \cdot 2 \cdot (y - y') \cdot (-1) \\&= y' - y \\&= 180 - 60 \\&= 120\end{aligned}$$

第一层参数全部初始化为0.5
第二层参数全部初始化为1
输入 $x_1=40, x_2=80$, 目标 $y=60$
学习率为 $1e-5$

反向传播算法

◆ 反向传播：计算第2层的梯度

第一层参数全部初始化为0.5
第二层参数全部初始化为1
输入 $x_1=40, x_2=80$, 目标 $y=60$
学习率为 $1e-5$



$$\begin{aligned}\frac{\partial L}{\partial w_{11}} &= \frac{\partial L}{\partial y'} \cdot \frac{\partial y'}{\partial z_1} \cdot \frac{\partial z_1}{\partial w_{11}} \\ &= 120 \times z_1 \\ &= 120 \times 60 \\ &= 7200\end{aligned}$$


$$\begin{aligned}\frac{\partial L}{\partial w_{21}} &= \frac{\partial L}{\partial y'} \cdot \frac{\partial y'}{\partial z_2} \cdot \frac{\partial z_2}{\partial w_{21}} \\ &= 120 \times z_2 \\ &= 120 \times 60 \\ &= 7200\end{aligned}$$

$$\begin{aligned}\frac{\partial L}{\partial w_{31}} &= \frac{\partial L}{\partial y'} \cdot \frac{\partial y'}{\partial z_3} \cdot \frac{\partial z_3}{\partial w_{31}} \\ &= 120 \times z_3 \\ &= 120 \times 60 \\ &= 7200\end{aligned}$$

反向传播算法

◆ 反向传播：计算第1层的梯度

第一层参数全部初始化为0.5
第二层参数全部初始化为1
输入 $x_1=40, x_2=80$, 目标 $y=60$
学习率为 $1e-5$



$$\begin{aligned}\frac{\partial L}{\partial w_{11}} &= \frac{\partial L}{\partial y'} \cdot \frac{\partial y'}{\partial z_1} \cdot \frac{\partial z_1}{\partial w_{11}} \\ &= 120 \times w_{11}^2 \times x_1 \\ &= 120 \times 1 \times 40 \\ &= 4800\end{aligned}$$

$$\begin{aligned}\frac{\partial L}{\partial w_{12}} &= \frac{\partial L}{\partial y'} \cdot \frac{\partial y'}{\partial z_2} \cdot \frac{\partial z_2}{\partial w_{12}} \\ &= 120 \times w_{12}^2 \times x_1 \\ &= 120 \times 1 \times 40 \\ &= 4800\end{aligned}$$

$$\begin{aligned}\frac{\partial L}{\partial w_{13}} &= \frac{\partial L}{\partial y'} \cdot \frac{\partial y'}{\partial z_3} \cdot \frac{\partial z_3}{\partial w_{13}} \\ &= 120 \times w_{13}^2 \times x_1 \\ &= 120 \times 1 \times 40 \\ &= 4800\end{aligned}$$

$$\begin{aligned}\frac{\partial L}{\partial w_{21}} &= \frac{\partial L}{\partial y'} \cdot \frac{\partial y'}{\partial z_1} \cdot \frac{\partial z_1}{\partial w_{21}} \\ &= 120 \times w_{21}^2 \times x_2 \\ &= 120 \times 1 \times 80 \\ &= 9600\end{aligned}$$


$$\begin{aligned}\frac{\partial L}{\partial w_{22}} &= \frac{\partial L}{\partial y'} \cdot \frac{\partial y'}{\partial z_2} \cdot \frac{\partial z_2}{\partial w_{22}} \\ &= 120 \times w_{22}^2 \times x_2 \\ &= 120 \times 1 \times 80 \\ &= 9600\end{aligned}$$

$$\begin{aligned}\frac{\partial L}{\partial w_{23}} &= \frac{\partial L}{\partial y'} \cdot \frac{\partial y'}{\partial z_3} \cdot \frac{\partial z_3}{\partial w_{23}} \\ &= 120 \times w_{23}^2 \times x_2 \\ &= 120 \times 1 \times 80 \\ &= 9600\end{aligned}$$

反向传播算法

◆ 梯度更新

第一层参数全部初始化为0.5
第二层参数全部初始化为1
输入 $x_1=40, x_2=80$, 目标 $y=60$
学习率为 $1e-5$



$$W = W - \eta \frac{\partial L}{\partial W}$$

$$\begin{aligned} w_{11}^2 &= w_{11}^2 - \eta \frac{\partial L}{\partial w_{11}^2} \\ &= 1 - 10^{-5} \times 7200 \\ &= 1 - 0.072 \\ &= 0.928 \end{aligned}$$

$$\begin{aligned} w_{21}^2 &= w_{21}^2 - \eta \frac{\partial L}{\partial w_{21}^2} \\ &= 1 - 10^{-5} \times 7200 \\ &= 1 - 0.072 \\ &= 0.928 \end{aligned}$$

$$\begin{aligned} w_{31}^2 &= w_{31}^2 - \eta \frac{\partial L}{\partial w_{31}^2} \\ &= 1 - 10^{-5} \times 7200 \\ &= 0.928 \end{aligned}$$

$$\begin{aligned} w_{11}^1 &= w_{11}^1 - \eta \frac{\partial L}{\partial w_{11}^1} \\ &= 0.5 - 10^{-5} \times 4800 \\ &= 0.5 - 0.048 \\ &= 0.452 \end{aligned}$$

$$\begin{aligned} w_{12}^1 &= w_{12}^1 - \eta \frac{\partial L}{\partial w_{12}^1} \\ &= 0.5 - 10^{-5} \times 4800 \\ &= 0.5 - 0.048 \\ &= 0.452 \end{aligned}$$

$$\begin{aligned} w_{13}^1 &= w_{13}^1 - \eta \frac{\partial L}{\partial w_{13}^1} \\ &= 0.5 - 10^{-5} \times 4800 \\ &= 0.5 - 0.048 \\ &= 0.452 \end{aligned}$$

$$\begin{aligned} w_{21}^1 &= w_{21}^1 - \eta \frac{\partial L}{\partial w_{21}^1} \\ &= 0.5 - 10^{-5} \times 9600 \\ &= 0.5 - 0.096 \\ &= 0.404 \end{aligned}$$


$$\begin{aligned} w_{22}^1 &= w_{22}^1 - \eta \frac{\partial L}{\partial w_{22}^1} \\ &= 0.5 - 10^{-5} \times 9600 \\ &= 0.5 - 0.096 \\ &= 0.404 \end{aligned}$$

$$\begin{aligned} w_{23}^1 &= w_{23}^1 - \eta \frac{\partial L}{\partial w_{23}^1} \\ &= 0.5 - 10^{-5} \times 9600 \\ &= 0.5 - 0.096 \\ &= 0.404 \end{aligned}$$

反向传播算法

◆ 重新进行前向传播

第一层参数全部初始化为0.5
第二层参数全部初始化为1
输入 $x_1=40, x_2=80$, 目标 $y=60$
学习率为 $1e-5$



$$\begin{aligned} z_1 &= w_{11}^1 x_1 + w_{21}^1 x_2 \\ &= 0.452 \times 40 + 0.404 \times 80 \\ &= 18.08 + 32.32 \\ &= 50.4 \end{aligned}$$

$$\begin{aligned} z_2 &= w_{12}^1 x_1 + w_{22}^1 x_2 \\ &= 0.452 \times 40 + 0.404 \times 80 \\ &= 50.4 \end{aligned}$$


$$\begin{aligned} z_3 &= w_{13}^1 x_1 + w_{23}^1 x_2 \\ &= 0.452 \times 40 + 0.404 \times 80 \\ &= 50.4 \end{aligned}$$

$$\begin{aligned} y' &= w_{11}^2 z_1 + w_{21}^2 z_2 + w_{31}^2 z_3 \\ &= 0.928 \times 50.4 \times 3 \\ &= 140.3136 \end{aligned}$$

反向传播算法

◆ 重新计算误差

第一层参数全部初始化为0.5
第二层参数全部初始化为1
输入 $x_1=40, x_2=80$, 目标 $y=60$
学习率为 $1e-5$



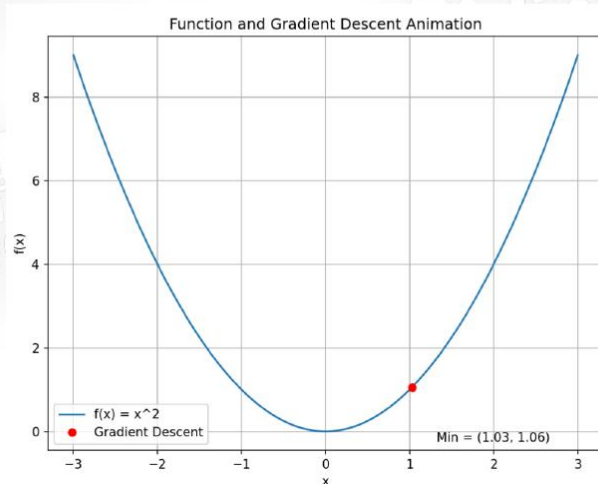
$$\begin{aligned} Loss &= \frac{1}{2}(y - y')^2 \\ &= \frac{1}{2}(60 - 140.3156)^2 \\ &\approx 3225.157 < 7200 (\text{更新前}) \end{aligned}$$

案例展示

代码实战：使用代码完成上述的神经网络反向传播

案例展示

代码实战：制作梯度下降求最小值的动画



案例展示

代码实战：实现三维平面的梯度下降

Gradient Descent on 3D Surface

