

典型卷积神经网络模型

目录


◆ 卷积神经网络模块

◆ LeNet5网络

卷积神经网络模块

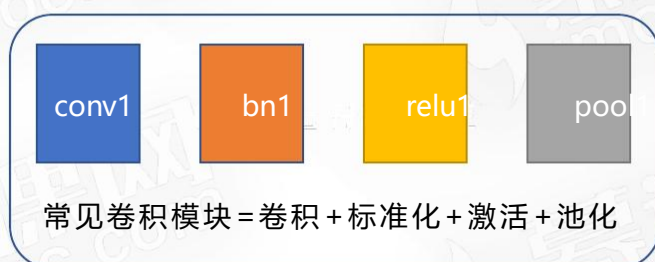
卷积神经网络基本结构

◆ 典型深度卷积神经网络结构



卷积模块

◆ 一般由卷积操作，池化操作，激活函数，标准化操作等组成



卷积与激活函数：必要

标准化和池化：非必要

全连接模块

◆ 一般由多个线性变换层，激活函数等组成

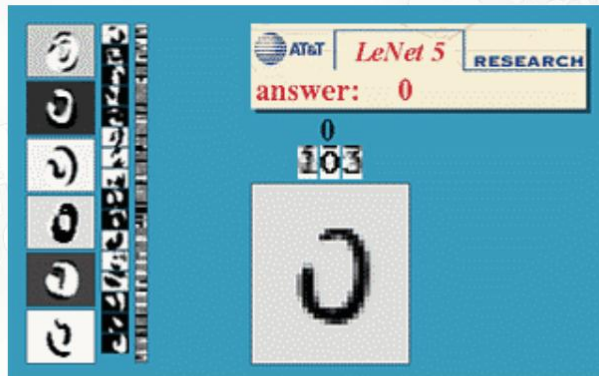


非输出的线性变换层必须要后接激活函数，输出变换层根据实际任务决定

LeNet5网络

LeNets5网络


- ◆ 1998年Yann LeCun等提出LeNets5，是第一个成功应用于手写数字识别问题并产生实际商业(邮政行业)价值的卷积神经网络。



来自于论文《Gradient-based learning applied to document recognition》

LeNets5网络细节

◆ 一共七层，3个卷积层，2个池化层，2个全连接层



输入图像: 32×32

三个卷积层: C1包括6个5×5卷积核 C3包括60个5×5卷积核 C5包括120×16个5×5卷积核


两个池化层S2和S4: 都是2×2的平均池化, 并添加了非线性映射

第一个全连接层: 84个神经元 第二个全连接层: 10个神经元

所有激活函数采用Sigmoid

LeNets5网络细节

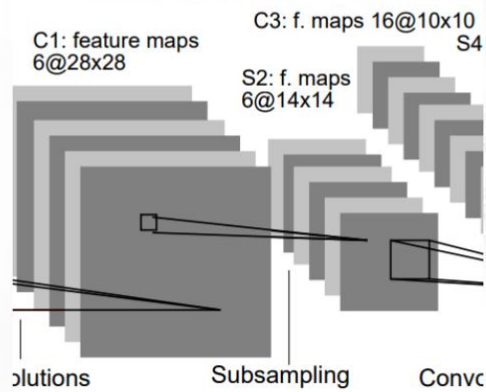
◆ C1层-卷积层



- 输入图片: 32*32
- 卷积核大小: 5*5
- 卷积核种类: 6
- 输出特征图大小: 28*28 $(32-5+1) = 28$
- 可训练参数: $(5*5+1) * 6$ (每个滤波器 $5*5=25$ 个unit参数和一个bias参数, 一共6个滤波器)

LeNets5网络细节


◆ S2层-池化层（下采样层）



- 输入：28*28
- 采样区域：2*2
- 采样方式：输入相加，乘以一个可训练参数，再加上一个可训练偏置，使用sigmoid激活
- 输出特征图大小：14*14 (28/2)

LeNets5网络细节

◆ C3层-卷积层



- 输入：S2中所有6个或者几个特征图组合
- 卷积核大小：5*5
- 卷积核种类：60
- 输出特征图大小：10*10 (14-5+1)
- 可训练参数：
$$6*(3*5*5+1)+6*(4*5*5+1)+3*(4*5*5+1)+1*(6*5*5+1)=1516$$

LeNets5网络细节

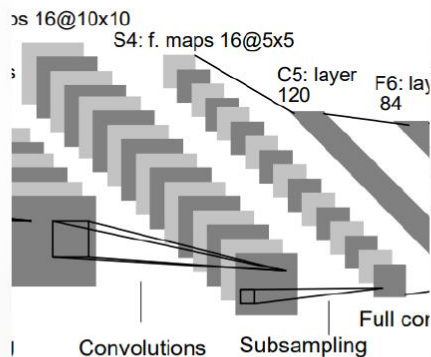
◆ C3层-非密集的特征图连接关系

S2 \ C3	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
0	X				X	X	X			X	X	X	X		X	X
1	X	X				X	X	X			X	X	X	X		X
2	X	X	X				X	X	X			X		X	X	X
3		X	X	X			X	X	X	X			X		X	X
4			X	X	X			X	X	X	X		X	X		X
5				X	X	X			X	X	X	X		X	X	X

C3的前6个特征图与S2层相连的3个特征图相连接，后面6个特征图与S2层相连的4个特征图相连接，后面3个特征图与S2层部分不相连的4个特征图相连接，最后一个与S2层的所有特征图相连。
采用非密集连接的方式，打破对称性，同时减少计算量，共60组卷积核

LeNets5网络细节


◆ S4层-池化层（下采样层）



- 输入：10*10
- 采样区域：2*2
- 采样方式：输入相加，乘以一个可训练参数，再加上一个可训练偏置，使用sigmoid激活
- 输出特征图大小：5*5 (10/2)

LeNets5网络细节


◆ C5层-卷积层



- 输入：S4层的全部16个单元特征map
- 卷积核大小：5*5
- 卷积核种类：120
- 输出特征图大小：1*1 (5-5+1)
- 可训练参数/连接：120* (16*5*5+1) = 48120

LeNets5网络细节

◆ F6层-全连接层



- 输入：c5 120维向量
- 计算方式：计算输入向量和权重向量之间的点积，再加上一个偏置，结果通过sigmoid函数输出。
- 可训练参数：84*(120+1)=10164

LeNets5网络细节

◆ F6全连接层的输出设计为什么是84个节点



计算机中字符的编码是ASCII编码，这些图是用7×12大小的位图表示，-1表示白色，1表示黑色，84可以用于对每一个像素点的值进行估计。

LeNets5网络细节

◆ Output层-全连接层，共有10个节点，分别代表数字0到9

$$y_i = \sum_j (x_j - w_{ij})^2$$

径向基函数（RBF）的网络连接方式，输入向量与参数向量的欧式距离。

x是激活后的输出，y是RBF的输出（误差值，最小的即为分类结果）， w_{ij} 是参数（人为设定的，取值-1或者1），i从0~9，j从0~83

下次预告：深度学习优化