

泛化与正则化

目录


◆ 什么是泛化与正则化

◆ 常见的正则化方法

什么是泛化与正则化

什么是泛化

- ◆ 所谓泛化(Generalization)，模型不仅在训练集表现良好，在未知的数据(测试集)也表现良好，即具有良好的泛化能力



过拟合(overfitting)与欠拟合(underfitting)


泛化不好的后果

- ◆ 模型性能不稳定，容易受到攻击



DOG
CAT(75.5%)

更改一个像素值攻击分类模型



增加贴纸攻击YOLO目标检测模型



增加贴纸攻击人脸识别模型

什么是正则化

- ◆ 所谓正则化(Regularization)，目标就是要同时让**经验风险**和**模型复杂度**都较小，是对模型的一种规则约束

(())

f 即预测结果函数， V 即损失函数。 $R(f)$ 是一个跟模型复杂度相关的单调递增函数，用于**约束模型的表达能力**。

正则化方法分类

正则化方法分类

◆ 显式正则化(经验正则化, 参数正则化)

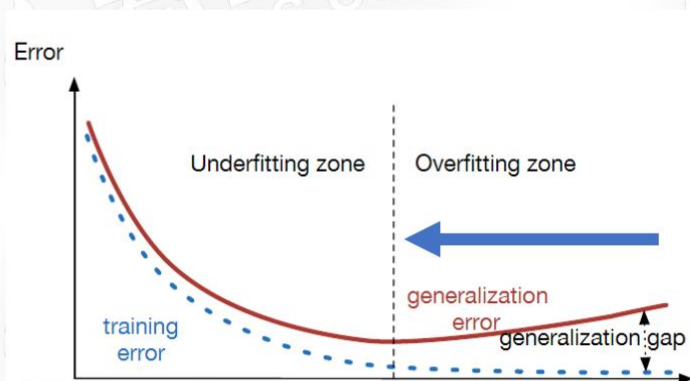
- 网络结构, 损失函数的修改, 模型使用方法的调整

◆ 隐式正则化

- 没有直接对模型进行正则化约束, 但间接获取更好的泛化能力

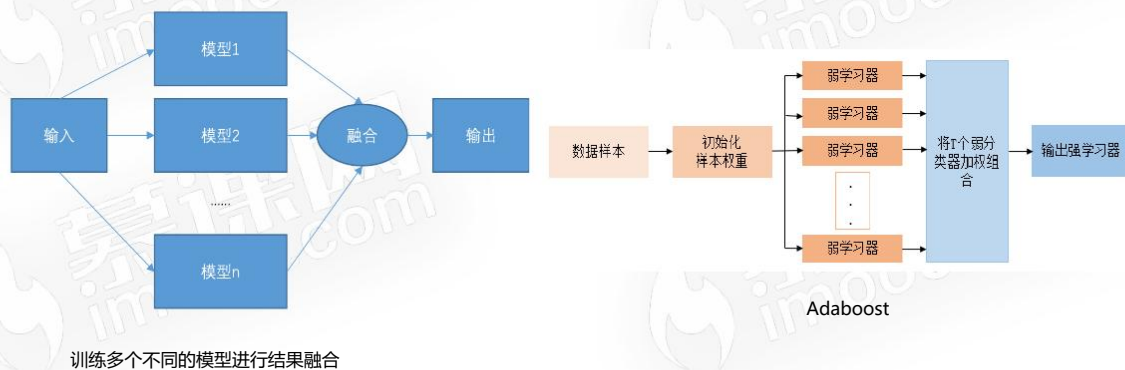
显式方法-提前终止

◆ 提前终止模型的训练



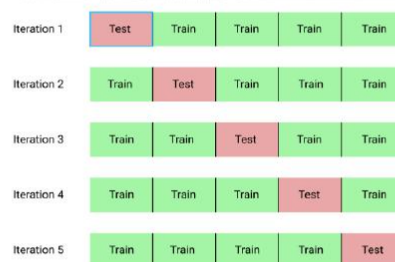
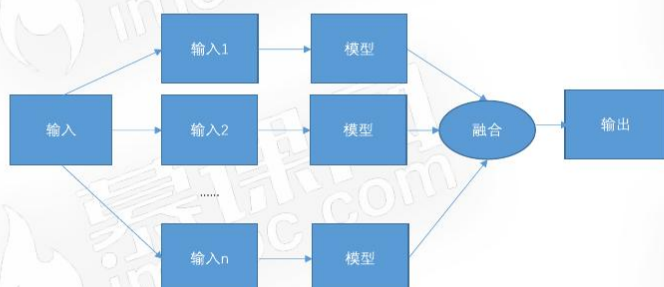
显式方法-模型集成

◆ 模型集成(Ensemble): 多次训练不同的模型进行结果融合



显式方法-模型集成


- ◆ 模型集成(Ensemble): 多次使用不同的数据训练模型进行结果融合



K折验证


显式方法-Maxout

- ◆ Maxout, 取N个激活的最大值



显式方法-Dropout


- ◆ 训练时按照概率 p 随机的丢弃一部分节点，测试时不丢弃，输出结果乘以 p




有 n 个节点的神经网络，可以看做是 2^n 个模型的集成，获得神经元的稀疏性

显式方法-Dropout

- ◆ Dropout带来更稀疏的激活模式，更多接近于0的激活值





(a) Without dropout




(b) Dropout with $p = 0.5$.

显式方法-Dropout

- ◆ Dropout带来更低的泛化误差与更好的特征提取器





(a) Without dropout



(b) Dropout with $p = 0.5$.

显式方法-Dropconnect

- ◆ Dropconnect, 随机去掉连接




Dropout和Dropconnect对比

显式方法-参数正则化

◆ L1正则化: $(w_1, w_2) \parallel_1$

◆ L2正则化: $(w_1, w_2) \parallel_2$




参数空间(w_1, w_2)是一个二维平面，蓝色部分是一个平方损失函数，黄色部分是正则项。


L2正则化的最优交点使得 w_1 或者 w_2 特别小。
L1正则化的最优交点使得 w_1 或者 w_2 等于0，获得所谓的稀疏化。

隐式正则化方法-数据标准化


◆ 数据标准化平滑了优化目标函数曲面



(a) loss landscape



(b) gradient predictiveness



(c) "effective" β -smoothness


隐式正则化方法-数据增强

- ◆ 扩大数据集规模



隐式正则化方法-随机参数更新

- ◆ 随机梯度下降算法，每次选取不同的样本，在不同的优化过程会获得不同结果



隐式正则化方法-标签平滑

◆ 标签平滑(label smoothing)



通过soft one-hot加入噪声，减少了真实样本标签的类别在计算损失函数时的权重，最终起到抑制过拟合的效果。

下次预告：学习率与最优化方法